

基于稀疏混合专家的缩放视觉

Carlos Riquelme *	an Puigcerver *	sil Mustafa *	xim Neumann
谷歌Brain	谷歌Brain	谷歌Brain	谷歌Brain
Rodolphe Jenatton	andr<e:1> Susano Pinto	Daniel Keysers	尼尔·霍斯比
谷歌BrainJo	谷歌BrainBa	谷歌BrainMa	谷歌Brain

摘要

稀疏门控混合专家网络(MoEs)在自然语言处理中表现出良好的可扩展性。然而，在计算机视觉中，几乎所有高性能网络都是“密集的”，也就是说，每个输入都由每个参数处理。我们提出了一种Vision MoE (V-MoE)，它是Vision Transformer的稀疏版本，具有可扩展性与最大的密集网络竞争。当应用于图像识别时，V-MoE的性能与最先进的网络相当，而在推理时间只需要一半的计算。此外，我们提出了对路由算法的扩展，该算法可以在整个批处理中优先考虑每个输入的子集，从而实现自适应的逐图计算。这允许V-MoE在测试时权衡性能和平滑计算。最后，我们展示了V-MoE在缩放视觉模型上的潜力，并在ImageNet上训练了一个15B参数的模型，该模型的准确率达到了90.35%。

1 简介

深度学习历史表明，增加网络容量和数据集大小通常会提高性能。在计算机视觉中，在大型数据集上预训练的大型模型通常可以达到最先进的水平[57,50,36,20,3]。这种方法在自然语言处理(NLP)中取得了更大的成功，其中大型预训练模型无处不在，并且在许多任务上表现非常好[48,18]。文本变形器[61]是迄今为止最大的模型，其中一些具有超过100B个参数[9]。然而，训练和服务这样的模型是昂贵的[56,46]。这部分是因为这些深度网络通常是“密集的”——每个示例都使用每个参数进行处理——因此，规模的计算成本很高。相比之下，条件计算[5]旨在增加模型容量，同时通过仅对每个示例应用一部分参数来保持训练和推理成本大致恒定。在NLP中，稀疏混合专家(MoEs)越来越受欢迎[54,39,22]，可以使用更少的资源进行训练和推理，同时解锁万亿参数模型。

在这项工作中，我们探索了大规模视觉的条件计算。我们介绍了视觉MoE (V-MoE)，这是最近用于图像分类的视觉变压器(ViT)架构[20]的稀疏变体。V-MoE用稀疏的MoE层取代ViT中密集前馈层的子集，其中每个图像补丁被“路由”到“专家”(MLP)的子集。由于独特的故障模式和不可微性，在深度稀疏模型中路由是具有挑战性的。我们探索了各种设计选择，并提出了一种有效的V-MoE的预训练和迁移配方，其性能明显优于密集的同类产品。我们进一步表明，V-MoE模型非常灵活。已经训练的模型的性能与推理成本之间的权衡可以在推理过程中通过调节相对于输入和/或模型权重的稀疏度水平来平滑地调整。

使用V-MoE，我们可以缩放到15B参数的模型尺寸，这是迄今为止最大的视觉模型。我们达到了最先进的密集模型的性能，同时需要更少的训练时间。

*These authors contributed equally. Correspondence to { rikel, jpucgserver, basilm }@google.com




图1:架构概览。V-MoE由L个ViT块组成。在某些情况下，我们用稀疏活化的MLP混合物代替MLP。每个MLP(专家)存储在单独的设备上，并处理固定数量的令牌。这个例子展示了这些令牌在设备之间的通信，它描述了每个令牌选择 $k = 1$ 个专家的情况。这里每个专家使用容量比 $C = 43$:稀疏MoE层每个设备接收12个令牌，但每个专家的容量为16($16 \cdot 12 = 192$;参见2.4节)。V-MoE的非专业组件，如路由器、注意力层和普通MLP块，在设备之间复制相同。

另外，V-MoE可以匹配ViT的成本，同时实现更好的性能。为了帮助控制这种权衡，我们提出了批处理优先路由，这是一种路由算法，它重新利用模型稀疏性来跳过一些补丁的计算，减少对非信息图像区域的计算。

我们总结了我们的主要贡献如下：

尺度上的视觉模型。我们提出了视觉混合专家模型，一个分布式稀疏激活的视觉变压器模型。我们训练的模型有多达24个MoE层，每层32位专家，几乎15B个参数。我们表明，这些模型可以稳定地训练，无缝地用于转移，并成功地微调了至少1 000个数据点。此外，我们最大的模型在经过微调后，在ImageNet上达到了90.35%的测试精度。

性能和推理。我们表明，V-MoEs在上游、少量和完全微调指标上的绝对性能明显优于密集的同类产品。此外，在推理时，V-MoE模型可以调整为(i)在使用少至一半的计算量或实际运行时间的情况下匹配最大密集模型的性能，或者(ii)在相同的成本下显着优于它。

批处理优先路由。我们提出了一种新的基于优先级的路由算法，允许V-MoEs丢弃最没用的补丁。因此，我们在每张图像上投入的计算更少。特别是，我们表明V-MoEs的性能与密集模型相当，同时节省了20%的训练flop。分析。我们提供了一些路由决策的可视化，揭示了有助于激励设计决策的模式和结论，并可能进一步提高该领域的理解。

2 视觉混合专家

我们首先描述MoEs和稀疏MoEs。然后，我们将介绍如何将这种方法应用于视觉，然后解释我们对路由算法和V-MoEs的实现的设计选择。

2.1 MoEs条件计算

条件计算旨在针对不同的输入激活网络的不同子集[5]。混合专家模型是一个特定的实例，其中不同的模型“专家”负责输入空间[31]的不同区域。

我们遵循[54]的设置，他为深度学习提供了一个由E个专家组成的混合层， $\text{MoE}(x) = \sum_{i=1}^E e_i(x) g_i(x)$ 其中 $x \in \mathbb{R}^D$ 是层的输入， e_i 是专家i计算的函数， g 是规定的“路由”函数

专家的输入条件权重。 e_i 和 g 都是通过神经网络参数化的。按照定义，这仍然是一个密集网络。然而，如果 g 是稀疏的，即被限制只分配 $k \ll E$ 非零权重，则不需要计算未使用的专家。这就解锁了相对于推理和训练计算的模型参数数量的超线性缩放。

2.2 MoEs for Vision

我们在视觉变压器(vision Transformer, ViT)[20]的背景下探讨稀疏性在视觉中的应用。ViT已被证明在迁移学习设置中具有良好的伸缩性，比使用较少预训练计算的cnn获得更好的准确性。ViT处理图像作为一个序列的补丁。输入图像首先被分成大小相等的小块网格。这些被线性投影到Transformer的[61]隐藏尺寸。添加位置嵌入后，由Transformer处理补丁嵌入(标记)，该Transformer主要由交替的自关注层和MLP层组成。

MLP有两层和一个GeLU[29]非线性： $MLP(x) = W_2 \sigma_{\text{gelu}}(W_1 x)$ 。对于视觉MoE，我们用MoE层替换其中的一个子集，其中每个专家都是一个MLP；见图1。专家的架构相同 $e_i(x) = MLP_{\theta_i}(x)$ 但权重不同 $\theta_i = (W_1^i, W_2^i)$ 。这遵循了与M4机器翻译模型[39]相似的设计模式。

2.3 路由

对于V-MoE中的每个MoE层，我们使用路由函数 $g(x) = \text{TOP}_k(\text{softmax}(Wx))$ ，其中 TOP_k 是将向量的所有元素设置为零的操作，除了 k 值最大的元素，是独立采样的 $\sim N(0, \frac{1}{E-1})$ 入口。在实际操作中，我们使用 $k = 1$ 或 $k = 2$ 。在Vision Transformer的上下文中， x 是网络某一层图像令牌的表示。因此，V-MoE路由补丁表示，而不是整个图像。

与之前的公式[54]的区别在于，我们在专家权重的softmax之后应用 TOP_k ，而不是之前。这允许我们在 $k = 1$ 的情况下训练(否则关于路由的梯度几乎处处为零)，并且在 $k > 1$ 的情况下表现更好(参见附录A)。

最后，我们在激活 Wx 中加入少量标准差为 $E1$ 的噪声，我们发现这样可以提高性能。我们经验地发现这表现得很好，但设置对这个参数是鲁棒的。噪声通常会在较早的层中改变 $\sim 15\%$ 的时间，在较深的层中改变 $\sim 2-3\%$ 的时间。

2.4 Expert's Buffer Capacity

在训练过程中，稀疏模型可能只偏爱一小部分专家[26,52]。这种常见的失效模式会导致两个问题。第一，统计效率低下：在单个专家崩溃的极限下，模型并不比密集模型更强大。第二，计算效率低下：将项目分配给专家的不平衡可能导致硬件利用率低下。

为了对抗不平衡并简化我们的实现，我们固定了每个专家的缓冲容量(即每个专家处理的令牌数量)，并使用辅助损失来训练我们的模型，以鼓励负载平衡。这本质上与[54,39,22]遵循的方法相同。在我们的案例中，我们使用[54]中提出的两种辅助损耗的轻微变体，如附录A所述。

我们将专家(B_e)的缓冲容量定义为批处理中的图像数量(N)、每张图像的令牌数量(P)、每个令牌所选择的专家数量(k)、专家总数(E)和容量比(C)的函数： $B_e = \text{round}(kNPC/E)$ 。

如果路由器将超过 B_e 个令牌分配给给定的专家，则只处理其中的 B_e 个令牌。剩下的令牌并没有完全“丢失”，因为它们的信息被剩余的连接保存了下来(图1的顶部图表)。此外，如果 $k > 1$ ，几个专家会尝试处理每个令牌。令牌永远不会被完全丢弃。如果分配给专家的令牌少于 B_e ，则其缓冲区的其余部分将被补零。

我们使用容量比率来调整专家的容量。对于 $C > 1$ ，增加了一个闲置容量，以解释潜在的路由不平衡。当新数据可能来自与上游训练期间非常不同的分布时，这通常对微调有用。当 $C < 1$ 时，路由器被迫忽略一些分配。在第4节中，我们提出了一种新的算法，该算法利用设置 $C \ll 1$ 来丢弃最没用的令牌，并在推理过程中节省计算时间。

3 迁移学习

在本节中，我们首先介绍在大型数据集(第3.2节)上训练V-MoE的不同变体，以便随后用于迁移学习。使用来自新任务的少量数据，轻松地使我们的海量模型适应新任务的能力是非常有价值的：它允许摊销跨多个任务的预训练成本。我们考虑了两种不同的迁移学习方法：固定表示的线性少镜头学习和模型的完全微调。

3.1 模型

我们在不同的ViT[20]变体上构建V-MoE：ViT-s(小)，ViT-b(大)，ViT-l(大)和ViT-h(大)，其超参数在附录B.5中描述。还有三个额外的主要设计决策会影响我们模型的成本(以及潜在的质量)：

MoE层数。在[39]之后，我们将MoEs放置在每个其他层上(我们将这些层称为V-MoE every -2)。此外，我们尝试使用更少的MoE层，将它们放置在最后 n 个偶数块上(因此我们将这些称为V-MoE last- n)。在附录E.1中，我们观察到，虽然使用较少的MoE层减少了模型的参数数量，但它通常对质量的影响很小，并且可以显著加快模型的速度，因为产生的通信开销较少。

选定专家的数量 k ：我们模型的成本不取决于专家的总数，而是取决于每个令牌选定的专家的数量。NLP中的并发工作固定 $k = 1$ [22]或 $k = 2$ [54,39]。在我们的例子中，我们默认使用 $k = 2$ (参见附录B中的图10，探索 k 的不同值)，而我们发现专家总数 $E = 32$ 是我们设置中的最佳点。

缓冲容量 C ：如2.4节所述，我们使用固定的缓冲容量。虽然这通常被认为是实现这些模型的缺点或工程困难，但我们可以调整容量比率来控制不同的权衡。我们可以有意地将其设置为较低的比率以节省计算，使用批处理优先化路由(见第4节)。在上游训练期间，我们默认设置 $C = 1.05$ 以提供少量的松弛，而不会明显增加成本。

请注意，对于给定的训练模型，后两个 k 和 c 可以在没有进一步训练的情况下进行调整，而专家层的定位和数量是有效固定的，以匹配预训练。

3.2 数据

我们在JFT-300M[57]上预训练我们的模型，这是一个半自动噪声标记数据集。它有~ 305M个训练图像和50000个验证图像，组织在18 291个类的层次结构中(平均每个图像1.89个标签)。我们对所有验证/测试集进行了重复数据删除，就像之前的工作[36].2一样

我们在ImageNet上的少量实验(即ILSVRC2012)每个类只使用1,5或10个镜头来适应上游模型，在验证集上评估结果模型。

我们还对完整训练集(约1M张图像)上的预训练模型进行了微调。我们在附录B.5中报告了其他四个数据集在类似机制下的性能。最后，我们通过在视觉任务适应基准(Visual Task Adaptation Benchmark, VTAB)[69]上对大型模型进行评估，探索了在低数据状态下对大型模型进行微调的能力。[VTAB]是一个由19个任务组成的多样化组合，每个任务只有1000个数据点。除了自然图像分类，VTAB还包括专门的任务(例如医疗或卫星图像)和结构化任务(例如计数或评估旋转/距离)。

3.3 上游结果

JFT是一个多标签数据集，所以我们通过precision@1来衡量模型的性能(详见附录B.6)。请注意，在之前的工作[20]中，超参数是为了传输性能而调整的，JFT精度可以通过牺牲下游任务来提高，例如通过减少权重衰减。图2a显示了不同V-MoE和ViT变体相对于总训练计算和时间的质量。从图中可以看出，模型选择 $k = 2$ 位专家，将MoEs放置在最后 n 个偶数块中(V-MoE-H $n = 5$ ，否则 $n = 2$)，但V-MoE-H/14 every -2的结果最好(见表2,14为patch大小)。所有模型的结果见附录B.5。

² We also checked the effect of deduplication with respect to the ImageNet *training* set, showing negligible (within noise) impact on few-shot results (only 1-shot worsened, see Table 9).




图2:JFT-300M Precision@1与ImageNet 5次射击精度。颜色代表不同的ViT变体，标记代表标准ViT或在最后n个偶数块上的V-MoEs。这些线表示ViT(虚线)和V-MoE(实线)变体的帕累托边界。




图3:ImageNet微调精度。颜色代表不同的ViT变体，标记代表标准ViT或在最后n个偶数块上的V-MoEs。线条表示ViT(虚线)和V-MoE(实线)的帕累托边界。

	ViT	V-MoE
L/16	76.3 $\pm$ 0.5	77.2 $\pm$ 0.4
H/14	77.6 $\pm$ 0.2	77.8 $\pm$ 0.4

表1:VTAB。ViT和V-MoE的分数和95%置信区间。

专家模型在所有模型大小上都提供了显著的收益，FLOPs只有轻微的增加，建立了一个新的帕累托边界(灰线)。或者，我们可以以更低成本匹配或提高ViT模型的性能(例如，V-MoE-L/16在v-h/14的基础上改进)。类似的结论也适用于训练时间，其中包括跨设备调度数据的通信开销。

3.4 线性少拍结果

我们评估使用few-shot线性迁移学习到的表示的质量。给定来自新数据集 $\{(X, Y)_i\}$ 的训练样例，我们使用预训练模型M提取每个图像的固定表示 $M(x_i)$ 。我们拟合一个线性回归模型，将 $M(x_i)$ 映射到目标标签 Y_i 的one-hot编码，遵循[20](参见[27，第5章]了解背景)。

图2b显示，考虑到计算和时间，在5次ImageNet评估下保留了上游增益;换句话说，在查看新任务时，V-MoE学习到的表示质量也优于ViT模型。表2进一步显示了一些选定模型的 $\{1, 10\}$ 射击结果，完整的详细结果见附录B.5。

3.5 完整的微调结果

迁移学习[19]通常最高效的方法包括用一个特定的任务的分类头替换上游分类头，并对整个模型进行微调。虽然人们可能会期望像V-MoEs这样的大型模型需要特殊的微调处理，但我们广泛遵循视觉变形器的标准微调协议。我们在微调过程中也使用辅助损耗，尽管我们观察到在这一步中通常不需要辅助损耗，因为路由器已经训练得很好。我们探讨了其中考虑的两组任务：

表2:主要V-MoE和ViT模型;表8显示了附加模型和数据集的结果。

Model	Params	JFT prec@1	IN/1shot	IN/5shot	IN/10shot	IN/Fine-t.	ExaFLOPs	TPUv3-days
ViT-H/14	656M	56.68	62.34	76.95	79.02	88.08	4.27k	2.38k
V-MoE-L/16, Every-2	3.4B	57.65	62.41	77.10	79.01	87.41	2.17k	1.20k
V-MoE-H/14, Last-5	2.7B	60.12	62.95	78.08	80.10	88.23	4.75k	2.73k
V-MoE-H/14, Every-2	7.2B	60.62	63.38	78.21	80.33	88.36	5.79k	3.47k
V-MoE-15B, Every-2	14.7B	—	68.66	82.78	84.29	90.35	33.9k	16.8k
NFNet-F4+ [8]	527M	—	—	—	—	89.20	—	1.86k
MPL [49]	480M	—	—	—	—	90.20	—	22.5k




图4:白色补丁是在第一层专家中丢弃的令牌，对于不同的容量，使用V-MoE-H/14的批处理优先路由(章节4.1)。更多示例见附录D。

完整数据。我们遵循[20]的设置，除了我们在专家mlp上应用0.1的失分率(就像[22]中所做的那样)，并且我们将除ImageNet之外的所有数据集的微调步骤数量减半。图3显示了ImageNet上的结果(三次运行的平均值)。在这里，V-MoE也比密集模型表现得更好，尽管我们怀疑微调协议可以进一步改进并针对稀疏模型进行定制。所有细节见表8，包括在其他数据集上的结果。

低数据状态。在VTAB基准测试中，我们使用与[20]类似的设置和超参数预算(但使用一半的调度长度进行微调)。表1显示，虽然V-MoE-H/14的性能相似，但专家在ViT-L/16级别提供了显著的增益，这表明尽管这些模型规模很大，但它们仍然可以使用少量数据进行微调，无需进一步的技巧。

3.6 扩展V-MoE

最后，我们测试了V-MoE如何将视觉模型扩展到非常多的参数，同时继续提高性能。为此，我们增加了模型的大小并使用了更大的预训练数据集:JFT-3B是JFT-300M的更大版本，它包含了近3B个图像，并用30k个类进行了噪声注释。受[68]的启发，我们应用了附录B.3中详细的更改，并训练了一个48块的V-MoE模型，每2个专家放置(32个专家， $k = 2$)，从而得到一个具有14.7B个参数的模型，我们用V-MoE-15B表示。

我们成功地训练了V-MoE-15B，据我们所知，这是迄今为止最大的视觉模型。在5张照片ImageNet上，它的准确率达到了令人印象深刻的82.78%，在完全微调时达到了90.35%，如附录B.5所示，其中还包括更多关于模型的细节。训练该模型需要16.8k TPUv3-core-days。为了将这个结果上下文化，ImageNet上目前的技术状态是Meta伪标记(MPL)[49]。MPL使用ImageNet伪标记在未标记的JFT-300M上训练基于efficientnet的模型，达到90.2%，同时需要22.5k TPUv3-core-days。

4 跳过令牌与批处理优先路由

我们提出了一种新的路由算法，允许模型优先考虑重要的令牌(对应。patch)。通过同时降低每个专家的能力，我们可以丢弃最没用的代币。直观地说，并不是每个补丁对给定图像的分类都同样重要，例如，大多数背景补丁可以被丢弃，让模型只关注具有相关实体的补丁。




图5:通过优先级路由减少计算量。大型模型的性能 vs. 推理 flop。具有原始香草路由的 v - moe 用 ● 表示, 而 * 显示 v - moe, 其中 BPR 和 $C \in \{0.6, 0.7, 0.8\}$ 和 $k \in \{1, 2\}$ 的混合被用来减少计算。显示为 x 的 ViT 模型。




图6: 优先级路由在 vanilla 失败的地方起作用。k = 2 时 V-MoE-H/14 模型的性能与推理能力比。即使是大型 C 公司的 BPR 也优于普通公司; 在低 C 的情况下, 差别就很明显了。BPR 仅处理 15-30% 的令牌, 与 dense 竞争。

4.1 从香草路由到批处理优先路由

使用第2节的符号, 将路由函数 g 逐行应用于一批输入 $X \in \mathbb{R}^{N \times P \times D_o}$ 。一个批包含 N 个图像, 每个图像由 P 个令牌组成; X 的每一行对应于图像的特定标记的 d 维表示。相应地, $g(X)_{ti} \in \mathbb{R}$ 表示第 t 个令牌和第 i 个专家的路由权重。

在所考虑的所有路由算法中, 对于 $i < j$, 每个 TOP- i 分配比任何 TOP- j 分配具有优先级。在分配任何第 j 个选择之前, 路由器首先尝试调度所有第 i 个专家选择³。

给定 TOP- i 位置, 在 [54, 39, 22] 中使用的默认路由或香草路由将令牌分配给专家如下。它依次遍历 $g(X)$ 的行, 并在专家的缓冲区未滿时将每个令牌分配给其 TOP- i 专家。因此, 根据 token 对应行的排名, 将优先级赋予 token。批处理中的图像是随机排序的, 而图像中的令牌则遵循预定义的固定顺序。该算法在附录 C 的算法 1 中有详细介绍。

批处理优先路由 (BPR)。为了有利于“最重要”的令牌, 我们建议在每个令牌上计算一个优先级分数 $s(x)$, 并在继续分配之前对 $g(x)$ 进行相应的排序。我们根据令牌的最大路由权重对其进行排序, 形式为 $s(X)_i = \max_i g(X)_{ti}$ 。TOP- k 权重的总和, 即 $s(X)_i = \sum_i g(X)_{ti}$, 效果同样好。这两种简单的方法优于我们探索的其他选项, 例如, 直接参数化和学习函数 s 。

我们重用路由器输出作为分配优先级的代理。我们的实验表明, 这保留了模型的高性能预测行为, 即使路由器输出主要编码令牌和专家可以配对的程度, 而不是令牌对最终分类任务的“重要性”。图4可视化了使用批处理优先路由对容量越来越小的令牌进行优先排序。由于批 X 中所有图像中的所有令牌都相互竞争, 因此不同的图像可能会接收到不同的计算量。我们在附录 C 中总结了算法 2 中的 BPR。

4.2 跳过低容量的令牌 C

批处理优先路由通过明智地选择要支持的令牌, 为减小缓冲区大小打开了大门。这可能会对整个稀疏模型的计算成本产生巨大影响。现在我们讨论第 2.4 节中定义的 C 在项 $C \ll 1$ 中的推断和训练结果。

³ A token may however successfully assign all its TOP- k choices while another may not allocate a single one. This can happen for instance if the latter selects very popular experts that run out of capacity.




图7:更深层次的路由决策与图像类别相关。我们展示了V-MoE-H/14的4个MoE层。x轴对应于一层中的32位专家。y轴是1000个ImageNet类;两个轴的排序在不同的地块上是不同的。对于每一对(专家e, 类c), 我们显示了该特定专家e的所有类c图像对应的令牌的平均路由权重。图29包括所有剩余的层;详情见附录E.2。

在推理时间。优先级路由与模型最初是如何训练的无关。图6显示了在使用vanilla路由训练的V-MoE-H/14模型上, 通过使用BPR和vanilla路由减少推理时计算量的效果。两种方法之间的性能差异是显著的——特别是当 $C \leq 0.5$ 时, 模型真正开始完全放弃令牌, 因为 $k = 2$ 。此外, BPR使该模型即使在相当低的容量下也能与密集模型竞争。如图5所示, 对于V-MoE-l/16和V-MoE-H/14, 批处理优先路由和低C允许V-MoE在推理时平滑地权衡性能和FLOPS, 这是一个非常独特的模型特征。更具体地说, 表10显示了V-MoE模型可以通过使用不到一半的FLOPs和不到60%的运行时间来击败密集的ViT-H性能。相反, 我们可以匹配推理FLOPs成本, 并在ImageNet/5shot中保持1点的精度增益, 在JFT精度中保持3点的精度增益(表11)。由于V-MoE实现中涉及的数据传输, 对于相同数量的FLOPs, 密集模型通常需要更少的运行时。

在训练时。批处理优先路由也可以在训练期间利用。在附录C中, 我们展示了具有最大权重路由的专家模型如何能够匹配密集性能, 同时节省大约20%的总训练FLOPs, 并且在具有类似FLOP预算的情况下远远优于vanilla。

5 模型分析

尽管大规模稀疏MoEs已经带来了强大的性能[22,39,54], 但对于这些复杂模型的内部工作原理知之甚少。我们认为, 这样的探索性实验可以为新算法的设计提供信息。在本节中, 我们首次提供了这种规模的分析, 它指导了本文中提出的算法的发展。

专业专家。直观地说, 路由器应该学会根据相似性在专家之间分发图像。例如, 如果模型有三个专家, 任务主要涉及三个类别——比如动物、汽车和建筑物——人们会期望专家专注于每一个类别。我们测试这种直觉, 有一些明显的注意事项:(a)专家被放置在几个网络深度, (b)k个专家被组合在一起, (c)路由发生在令牌而不是图像级别。

图7说明了给定ImageNet类的多少张图像使用了每个专家。这些图是通过运行一个经过微调的V-MoE-H每2模型生成的。有趣的是, 我们在没有微调的上游模型中看到了类似的模式。专家专门区分小的类集(那些主要通过专家路由的类集)。在早期的MoE层中, 我们没有观察到这一点。专家可能会转而关注所有类的共同方面(背景、基本形状、颜色)——例如, 图30(附录E)显示了早期层中与补丁位置的相关性。

路由器的价值。在训练了一个稀疏的MoE之后, 考虑到几个陷阱, 研究学习到的路由器的有用性是很自然的。例如, 如果专家最终学习到非常相似的功能, 路由器可能只是充当负载均衡器, 或者路由器可能只是选择了糟糕的分配。在附录E.1中, 我们在训练之后, 用一个均匀随机的路由器一次替换一个路由器。该模型对早期路由变化具有鲁棒性, 同时对最后一层的决策更加敏感。

路由权重分布。我们分析了附录E.3中的路由器输出，并观察到所选权重的分布在不同的专家层混合中差异很大。

在推理时改变 k 。我们已经观察到专家模型非常灵活。有些令人惊讶的是，稀疏模型对于训练和推理配置之间的不匹配具有相当强的鲁棒性。在附录E.4中，我们探讨了使用某些原始 k 值进行训练的效果，同时在不同 $k' \neq k$ 的推理时间应用该模型。这可以方便地控制(减少或增加)特定生产系统中每个输入的FLOPs数量。

6 相关工作

条件计算。为了在不按比例增加计算成本的情况下增加模型参数的数量，条件计算[5,15,12]只以依赖输入的方式激活模型的一些相关部分，就像决策树[7]中一样。在深度学习中，部分模型的激活可以使用随机神经元[6]或强化学习[4,17,53]。

混合专家。MoEs[31,34,10,66]通过路由器以输入依赖的方式组合被称为专家的子模型的输出。MoEs已经成功地在一系列应用中使用了这种形式的条件计算[23,30,58,55,67]。输入既可以选择所有专家[21]，也可以像最近的大规模语言模型[54,39,22]一样选择它们的稀疏混合。

语言的MoEs。MoEs最近将语言模型扩展到数万亿个参数。我们的方法受到[54]的启发，[54]提出了lstm中的top- k 门控，辅助损失确保专家平衡[26]。[39]进一步将这种方法扩展到变压器，显示出神经机器翻译的强大收益。与密集基线[50]相比，[22]拥有超过一万亿参数和每个输入一位专家，加速了预训练，同时显示了由于转移和蒸馏而获得的收益。[40]通过解决线性分配问题来强制执行平衡路由。

视觉MoEs。对于计算机视觉，之前关于MoEs的研究[21,2,25,1,63,47,64]关注的是规模比语言模型和我们的模型都小得多的体系结构。在DeepMoE[63]中，“专家”是由多头稀疏门自适应选择的卷积层的通道。这类似于[64]，其中卷积层的核是在每个示例的基础上被激活的。其他方法使用浅MoEs，学习单个路由器，要么是disjoint[25]，要么是joint[2]，与cnn一起扮演专家的角色。[1]进一步有一个成本意识的过程来对专家之间的输入分配进行偏置。与浅层MoEs不同，我们沿着模型的深度对每个令牌进行多达数十个路由决策。扩展路由深度被标记为[51]中的一个主要挑战，我们在工作中成功地解决了这个问题。

7 结论

我们已经使用稀疏条件计算来训练一些迄今为止最大的视觉模型，在表示学习和迁移学习方面显示出显著的改进。除了V-MoE，我们还提出了批优先路由，它允许成功地重新利用模型稀疏性来引入相对于输入的稀疏性。这可以在不进一步调整模型的情况下完成，允许重用具有稀疏条件计算的训练模型。

这对于最近使用稀疏模型的NLP工作具有有趣的内涵；最近的分析表明，模型稀疏性是减少模型CO₂排放[46]的最有希望的方法，并且90%的足迹源于推理成本-我们提出了一种算法，该算法采用最有效的模型，并使其更有效，而无需任何进一步的模型适应。

这只是视觉尺度条件计算的开始；扩展包括扩大专家数量，减少对数据的依赖，改善稀疏模型产生的表示的传输。与异质专家架构和条件变长路由相关的方向也应该是富有成果的。我们期望稀疏模型缩放的重要性日益增加，特别是在数据丰富的领域，如大规模多模态或视频建模。

致谢和资金披露

我们感谢Alex Kolesnikov、Lucas Beyer和Xiaohua翟晓华，感谢他们在缩放ViT模型方面不断提供帮助和细节;Alexey Dosovitskiy，他提供了一些预训练的ViT模型;伊利亚·托尔斯提欣(Ilya Tolstikhin)，他建议只把专家放在最后一层;Josip Djolonga对手稿的早期审阅;Dmitry Lepikhin提供了关于原始GShard实现的细节;Barret Zoph和Liam Fedus提供了有见地的评论和反馈;James Bradbury, Blake Hechtman以及JAX和TPU团队的其他成员，他们帮助我们高效地运行我们的模型，以及谷歌Brain的许多其他人的支持。

参考资料

- [1] A. Abbas and Y. Andreopoulos. Biased mixtures of experts: Enabling computer vision inference under data transfer limitations. *IEEE Trans. Image Processing*, 29:7656–7667, 2020.
- [2] K. Ahmed, M. H. Baig, and L. Torresani. Network of experts for large-scale image categorization. In *ECCV*, 2016.
- [3] A. Arnab, M. Dehghani, G. Heigold, C. Sun, M. Lu[∨]ci[´]c, and C. Schmid. ViViT: A video vision transformer. *arXiv preprint arXiv:2103.15691*, 2021.
- [4] E. Bengio, P.-L. Bacon, J. Pineau, and D. Precup. Conditional computation in neural networks for faster models. *arXiv preprint arXiv:1511.06297*, 2015.
- [5] Y. Bengio. Deep learning of representations: Looking forward. In *International Conference on Statistical Language and Speech Processing*, pages 1–37, 2013.
- [6] Y. Bengio, N. Léonard, and A. Courville. Estimating or propagating gradients through stochastic neurons for conditional computation. *arXiv preprint arXiv:1308.3432*, 2013.
- [7] L. Breiman, J. Friedman, C. J. Stone, and R. A. Olshen. *Classification and regression trees*. CRC press, 1984.
- [8] A. Brock, S. De, S. L. Smith, and K. Simonyan. High-performance large-scale image recognition without normalization. *arXiv preprint arXiv:2102.06171*, 2021.
- [9] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, et al. Language models are few-shot learners. *arXiv preprint arXiv:2005.14165*, 2020.
- [10] K. Chen, L. Xu, and H. Chi. Improved learning algorithms for mixture of experts in multiclass classification. *Neural networks*, 12(9):1229–1252, 1999.
- [11] G. Cheng, J. Han, and X. Lu. Remote sensing image scene classification: Benchmark and state of the art. *Proceedings of the IEEE*, 105(10):1865–1883, Oct 2017.
- [12] K. Cho and Y. Bengio. Exponentially increasing the capacity-to-computation ratio for conditional computation in deep learning. *arXiv preprint arXiv:1406.7362*, 2014.
- [13] M. Cimpoi, S. Maji, I. Kokkinos, S. Mohamed, and A. Vedaldi. Describing textures in the wild. In *Computer Vision and Pattern Recognition (CVPR)*, 2014.
- [14] E. D. Cubuk, B. Zoph, J. Shlens, and Q. Le. Randaugment: Practical automated data augmentation with a reduced search space. In H. Larochelle, M. Ranzato, R. Hadsell, M. F. Balcan, and H. Lin, editors, *Advances in Neural Information Processing Systems*, 2020.
- [15] A. Davis and I. Arel. Low-rank approximations for conditional feedforward computation in deep neural networks. *arXiv preprint arXiv:1312.4461*, 2013.
- [16] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei. ImageNet: A large-scale hierarchical image database. In *CVPR*, 2009.
- [17] L. Denoyer and P. Gallinari. Deep sequential neural network. *arXiv preprint arXiv:1410.0510*, 2014.
- [18] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *NAACL*, 2019.
- [19] G. S. Dhillon, P. Chaudhari, A. Ravichandran, and S. Soatto. A baseline for few-shot image classification. In *ICLR*, 2020.

- [20] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *ICLR*, 2021.
- [21] D. Eigen, M. Ranzato, and I. Sutskever. Learning factored representations in a deep mixture of experts. *arXiv preprint arXiv:1312.4314*, 2013.
- [22] W. Fedus, B. Zoph, and N. Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. *arXiv preprint arXiv:2101.03961*, 2021.
- [23] D. M. Gavrilu and S. Munder. Multi-cue pedestrian detection and tracking from a moving vehicle. *International journal of computer vision*, 73(1):41–59, 2007.
- [24] A. Geiger, P. Lenz, and R. Urtasun. Are we ready for autonomous driving? The KITTI vision benchmark suite. In *Computer Vision and Pattern Recognition (CVPR)*, 2012.
- [25] S. Gross, M. Ranzato, and A. Szlam. Hard mixtures of experts for large scale weakly supervised vision. In *CVPR*, 2017.
- [26] J. V. Hansen. Combining predictors: comparison of five meta machine learning methods. *Information Sciences*, 119(1-2):91–105, 1999.
- [27] T. Hastie, R. Tibshirani, and J. Friedman. *The elements of statistical learning: data mining, inference, and prediction*. Springer, 2017.
- [28] P. Helber, B. Bischke, A. Dengel, and D. Borth. EuroSAT: A novel dataset and deep learning benchmark for land use and land cover classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 12(7):2217–2226, 2019.
- [29] D. Hendrycks and K. Gimpel. Gaussian error linear units (gelus). *arXiv preprint arXiv:1606.08415*, 2016.
- [30] Y. H. Hu, S. Palreddy, and W. J. Tompkins. A patient-adaptable ECG beat classifier using a mixture of experts approach. *IEEE Trans. Biomedical Engineering*, 44(9):891–900, 1997.
- [31] R. A. Jacobs, M. I. Jordan, S. J. Nowlan, and G. E. Hinton. Adaptive mixtures of local experts. *Neural Computation*, 3(1):79–87, 1991.
- [32] Z. Jiang, Q. Hou, L. Yuan, D. Zhou, X. Jin, A. Wang, and J. Feng. Token labeling: Training a 85.5% top-1 accuracy vision transformer with 56m parameters on imagenet. *arXiv preprint arXiv:2104.10858*, 2021.
- [33] J. Johnson, B. Hariharan, L. van der Maaten, F.-F. Li, C. Lawrence Zitnick, and R. Girshick. CLEVR: A diagnostic dataset for compositional language and elementary visual reasoning. In *Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [34] M. I. Jordan and R. A. Jacobs. Hierarchical mixtures of experts and the EM algorithm. *Neural computation*, 6(2):181–214, 1994.
- [35] Kaggle and EyePacs. Kaggle diabetic retinopathy detection, 2015.
- [36] A. Kolesnikov, L. Beyer, X. Zhai, J. Puigcerver, J. Yung, S. Gelly, and N. Houlsby. Big transfer (BiT): General visual representation learning. In *ECCV*, 2020.
- [37] A. Krizhevsky. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.
- [38] Y. LeCun, F. J. Huang, and L. Bottou. Learning methods for generic object recognition with invariance to pose and lighting. In *Computer Vision and Pattern Recognition (CVPR)*, 2004.
- [39] D. Lepikhin, H. Lee, Y. Xu, D. Chen, O. Firat, Y. Huang, M. Krikun, N. Shazeer, and Z. Chen. GShard: Scaling giant models with conditional computation and automatic sharding. In *ICLR*, 2021.
- [40] M. Lewis, S. Bhosale, T. Dettmers, N. Goyal, and L. Zettlemoyer. Base layers: Simplifying training of large, sparse models. *arXiv preprint arXiv:2103.16716*, 2021.
- [41] F.-F. Li, R. Fergus, and P. Perona. Learning generative visual models from few training examples: An incremental Bayesian approach tested on 101 object categories. *Computer Vision and Pattern Recognition Workshop*, 2004.
- [42] L. Matthey, I. Higgins, D. Hassabis, and A. Lerchner. dSprites: Disentanglement testing sprites dataset, 2017.

- [43] Y. Netzer, T. Wang, A. Coates, A. Bissacco, and A. Y. Ng. Reading digits in natural images with unsupervised feature learning. In *NIPS Workshop on Deep Learning and Unsupervised Feature Learning 2011*, 2011.
- [44] M.-E. Nilsback and A. Zisserman. Automated flower classification over a large number of classes. In *Sixth Indian Conf. on Computer Vision, Graphics & Image Processing*, 2008.
- [45] O. M. Parkhi, A. Vedaldi, A. Zisserman, and C. Jawahar. Cats and dogs. In *CVPR*, 2012.
- [46] D. Patterson, J. Gonzalez, Q. Le, C. Liang, L.-M. Munguia, D. Rothchild, D. So, M. Texier, and J. Dean. Carbon emissions and large neural network training. *arXiv preprint arXiv:2104.10350*, 2021.
- [47] S. Pavlitskaya, C. Hubschneider, M. Weber, R. Moritz, F. Huger, P. Schlicht, and M. Zollner. Using mixture of expert models to gain insights into semantic segmentation. In *CVPR Workshops*, 2020.
- [48] M. E. Peters, M. Neumann, M. Iyyer, M. Gardner, C. Clark, K. Lee, and L. Zettlemoyer. Deep contextualized word representations. In *NAACL*, 2018.
- [49] H. Pham, Z. Dai, Q. Xie, M.-T. Luong, and Q. V. Le. Meta pseudo labels. *arXiv preprint arXiv:2003.10580*, 2020.
- [50] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *arXiv preprint arXiv:1910.10683*, 2019.
- [51] P. Ramachandran and Q. V. Le. Diversity and depth in per-example routing models. In *ICLR*, 2018.
- [52] C. Rosenbaum, I. Cases, M. Riemer, and T. Klinger. Routing networks and the challenges of modular and compositional computation. *arXiv preprint arXiv:1904.12774*, 2019.
- [53] C. Rosenbaum, T. Klinger, and M. Riemer. Routing networks: Adaptive selection of non-linear functions for multi-task learning. *arXiv preprint arXiv:1711.01239*, 2017.
- [54] N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. Le, G. Hinton, and J. Dean. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. In *ICLR*, 2017.
- [55] C. Sminchisescu, A. Kanaujia, Z. Li, and D. Metaxas. Learning to reconstruct 3D human motion from Bayesian mixtures of experts. A probabilistic discriminative approach. *Dept. Comput. Sci., Univ. Toronto, Tech. Rep. CSRG-502*, 2004.
- [56] E. Strubell, A. Ganesh, and A. McCallum. Energy and policy considerations for deep learning in NLP. *arXiv preprint arXiv:1906.02243*, 2019.
- [57] C. Sun, A. Shrivastava, S. Singh, and A. Gupta. Revisiting unreasonable effectiveness of data in deep learning era. In *ICCV*, 2017.
- [58] J. Tani and S. Nolfi. Learning to perceive the world as articulated: an approach for hierarchical learning in sensory-motor systems. *Neural Networks*, 12(7-8):1131–1141, 1999.
- [59] H. Touvron, M. Cord, M. Douze, F. Massa, A. Sablayrolles, and H. Jégou. Training data-efficient image transformers & distillation through attention. *arXiv preprint arXiv:2012.12877*, 2020.
- [60] H. Touvron, M. Cord, A. Sablayrolles, G. Synnaeve, and H. Jégou. Going deeper with image transformers. *arXiv preprint arXiv:2103.17239*, 2021.
- [61] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need. In *NeurIPS*, 2017.
- [62] B. S. Veeling, J. Linmans, J. Winkens, T. Cohen, and M. Welling. Rotation equivariant CNNs for digital pathology. In *Medical Image Computing and Computer Assisted Intervention (MICCAI)*, 2018.
- [63] X. Wang, F. Yu, L. Dunlap, Y.-A. Ma, R. Wang, A. Mirhoseini, T. Darrell, and J. E. Gonzalez. Deep mixture of experts via shallow embedding. In *Uncertainty in Artificial Intelligence*, 2020.
- [64] B. Yang, G. Bender, Q. V. Le, and J. Ngiam. Condconv: Conditionally parameterized convolutions for efficient inference. *arXiv preprint arXiv:1904.04971*, 2019.
- [65] L. Yuan, Y. Chen, T. Wang, W. Yu, Y. Shi, F. E. Tay, J. Feng, and S. Yan. Tokens-to-token vit: Training vision transformers from scratch on imagenet. *arXiv preprint arXiv:2101.11986*, 2021.

- [66] S. E. Yuksel, J. N. Wilson, and P. D. Gader. Twenty years of mixture of experts. *IEEE transactions on neural networks and learning systems*, 23(8):1177–1193, 2012.
- [67] A. J. Zeevi, R. Meir, and R. J. Adler. Time series prediction using mixtures of experts. In *NeurIPS*, 1997.
- [68] X. Zhai, A. Kolesnikov, N. Houlsby, and L. Beyer. Scaling vision transformers, 2021.
- [69] X. Zhai, J. Puigcerver, A. Kolesnikov, P. Ruysen, C. Riquelme, M. Lucic, J. Djolonga, A. S. Pinto, M. Neumann, A. Dosovitskiy, L. Beyer, O. Bachem, M. Tschannen, M. Michalski, O. Bousquet, S. Gelly, and N. Houlsby. A large-scale study of representation learning with the visual task adaptation benchmark. *arXiv preprint arXiv:1910.04867*, 2019.
- [70] X. Zhai, J. Puigcerver, A. Kolesnikov, P. Ruysen, C. Riquelme, M. Lucic, J. Djolonga, A. S. Pinto, M. Neumann, A. Dosovitskiy, et al. A large-scale study of representation learning with the visual task adaptation benchmark. *arXiv preprint arXiv:1910.04867*, 2019.

表3:路由功能比较。

Model	Routing Function	Proposed in	K	prec@1	ImageNet/1shot	ImageNet/5shot	ImageNet/10shot
VIT-S/32	TOP-K(softmax)	This work	2	34.15	38.42	53.11	56.06
VIT-S/32	softmax(TOP-K)	[54]	2	33.75	35.59	50.21	53.63

表4:简单的例子($k = 1$), 其中平均权重是平衡的, 但专家2从未被选中。

Token	Expert 1	Expert 2	Expert 3	Selected Expert
	w_1	w_2	w_3	
x_1	0.9	0.5	0.1	Expert 1
x_2	0.1	0.5	0.9	Expert 3
x_3	0.9	0.5	0.1	Expert 1
x_4	0.1	0.5	0.9	Expert 3
...	...	...	...	...

A关于专家的视觉混合的进一步细节

在本节中, 我们提供关于V-MoE定义的更多细节。

A.1 消融关于路由功能的修改

我们的公式与[54]中的类似, 不同之处在于我们在专家权值归一化后应用了“top k”操作, 即TOP_k和softmax的应用顺序相反。

我们之所以选择这种排序, 是因为在 $k = 1$ 的情况下, [54]的原始公式不容易训练;它会导致几乎在任何地方对 x 和 w 的梯度为零。此外, 即使对于 $k > 1$, 我们发现我们的替代公式表现更好(见表3)。

A.2 负载均衡损失的描述

我们将在下面描述用于强制均衡使用专家的正则化器。这些正则表达式相对于[54]中的原始定义进行了轻微的修改。

重要性损失。我们通过重要性损失来激励专家的平衡使用。专家 i 对一批图像 X 的重要性定义为对图像求和的专家 i 对应的归一化路由权重:

$$\text{Imp}_i(\mathbf{X}) := \sum_{\mathbf{x} \in \mathbf{X}} \text{softmax}(\mathbf{W}\mathbf{x})_i, \quad (1)$$

其中 $\mathbf{W}$ 为路由器的层特定权重矩阵。我们使用专家重要性分布的变异系数平方, $\text{Imp}(\mathbf{X}) := \{\text{Imp}_i(\mathbf{X})\}_{i=1}^E$:

$$\mathcal{L}_{\text{Imp}}(\mathbf{X}) = \left(\frac{\text{std}(\text{Imp}(\mathbf{X}))}{\text{mean}(\text{Imp}(\mathbf{X}))} \right)^2 \propto \text{var}(\text{Imp}(\mathbf{X})). \quad (2)$$

[54]提出了类似的损失, 而在他们的情况下, 只有当 i 确实被 x 选中时, 令牌 x 才会对方程(1)中专家 i 的重要性做出贡献。由于方程(2), 我们观察到一些适度的经验效益。

负载损失(Load Loss)重要性损失旨在保证所有专家平均具有相似的输出路由权重。不幸的是, 不难想到这些权重总体上是平衡的路由配置, 但是, 仍然有一小部分专家获得了所有的分配(见表4)。

理想情况下, 我们也希望显式地平衡分配的数量。这个数量是离散的;因此它是不可微的, 我们需要依赖一个代理。按照[54]中的提议, 对于每个专家 i 和令牌 x , 我们计算 i 被选中的概率——即, 即在

如果我们只对专家 i 的噪声重新采样, 则为 $\mathbf{x}$ 的top-k。为了简单起见, 我们稍微修改了[54]中的定义。对于每个令牌 $\mathbf{x}$, 我们定义高于该分数阈值的专家被选中; 这简单来说就是第 k 个最大分数:

$$\text{threshold}_k(\mathbf{x}) := \max_{k\text{-th}}(W\mathbf{x} + \epsilon), \quad (3)$$

其中为前向传递过程中最初采样的噪声向量。然后, 对于每个专家 i , 如果我们只重新采样它的噪声, 我们计算 i 高于阈值的概率:

$$p_i(\mathbf{x}) := \mathbf{P}((W\mathbf{x})_i + \epsilon_{\text{new}} \geq \text{threshold}_k(\mathbf{x})) = \mathbf{P}(\epsilon_{\text{new}} \geq \text{threshold}_k(\mathbf{x}) - (W\mathbf{x})_i). \quad (4)$$

概率定义在 $\epsilon_{\text{new}} \sim N(0, \sigma^2)$ 上, $\sigma = 1/E_0$ 。批 $\mathbf{X}$ 上专家 i 的负载为:

$$\text{load}_i(\mathbf{X}) = \sum_{\mathbf{x} \in \mathbf{X}} p_i(\mathbf{x}). \quad (5)$$

最后, 负荷损失对应于负荷分布的变异系数平方:

$$\mathcal{L}_{\text{load}}(\mathbf{X}) = \left(\frac{\text{std}(\text{load}(\mathbf{X}))}{\text{mean}(\text{load}(\mathbf{X}))} \right)^2, \quad \text{load}(\mathbf{X}) := \{\text{load}_i(\mathbf{X})\}_{i=1}^E. \quad (6)$$

Final Auxiliary Loss。最终辅助损失只是两者的平均值:

$$\mathcal{L}_{\text{aux}}(X) = \frac{1}{2} \mathcal{L}_{\text{imp}}(X) + \frac{1}{2} \mathcal{L}_{\text{load}}(X). \quad (7)$$

总体损失为: $L(X) = L_{\text{classification}}(X) + \lambda L_{\text{aux}}(X)$, 对于某些超参数 $\lambda > 0$ 。我们在所有实验中设置 $\lambda = 0.01$, 观察到这种选择是鲁棒的, 不敏感的。

表5:微调数据集。

Dataset	Num examples	Num classes
CIFAR10 [37]	50 000	10
CIFAR100 [37]	50 000	100
Oxford Flowers 102 [44]	1 020	102
Oxford-IIT Pet [45]	3 680	37
ImageNet (ILSVRC2012 [16])	1 281 167	1 000

表6:JFT上游训练的超参数值。权重衰减0.1表示该值应用于所有模型参数(包括偏置), 而(0.03,3)表示0.03用于核, 3用于分类头。

Variant	JFT-300M Epochs	Optimizer	Base LR	LR decay	Weight Decay
S/32	5	Adam	$1 \cdot 10^{-3}$	linear	0.1
B/16,32	7	Adam	$8 \cdot 10^{-4}$	linear	0.1
L/32	7	Adam	$6 \cdot 10^{-4}$	linear	0.1
L/16	{7,14}	Adam	$4 \cdot 10^{-4}$	linear	0.1
H/14	14	Adam	$3 \cdot 10^{-4}$	linear	0.1
V-MoE-15B	—	Adafactor	$8 \cdot 10^{-4}$	rsqr ^a	(0.03, 3)

^a在训练结束时应用线性学习率冷却时间。

B 迁移实验细节

B.1 额外的微调数据集

除了在ImageNet (ILSVRC2012[16])上进行微调外, 我们还在表5所示的其他四个数据集上进行训练。对于视觉任务适应基准(VTAB[70]), 我们在19个数据集上进行微调, 每个类有1000个数据点。我们建议感兴趣的读者参考Zhai等人的原著[70]了解更多细节, 但简而言之, 基准测试由3个任务类别组成:

- 自然任务 CalTech101[41]、CIFAR100[37]、Street查看房号(SVHN-[43])、可描述纹理(DTD-[13])、OxfordFlowers[44]、OxfordPets[45] 这些任务包含用相机获得的“经典”自然真实世界图像。
- 专业任务 EuroSAT[28]、DiabeticRetinopathy [35] PatchCamelyon[62]、Remote传感图像场景分类(resist-[11]) 这些是用专业(医疗, 卫星等)摄影设备捕获的图像的数据集。
- 结构化数据集 DeepMind实验室(物体距离预测-[69])、SmallNOrb(方位角和高程预测-[38]) CLEVR(计数和距离预测[33])、Kitti(车辆距离预测[24])、dSprites(像素位置和方向预测-[42]) 这些以某种方式评估对场景结构的理解, 主要来自合成环境。示例任务包括3D深度估计和计数。

B.2 上游超参数

我们在表8中给出了上游模型的架构细节(嵌入大小——相当于隐藏大小、MLP维度、Transformer块的数量等)。表6显示了我们主要模型的训练超参数。我们对每个ViT模型[20]使用原始设置。然而, [20]中并没有正式引入vits, 我们的vits参数(dense and sparse)与[59]中引入的DeiT-Small并不匹配。

表7:对不同数据集进行微调的超参数值。

Dataset	Steps	Base LR	Expert Dropout
ImageNet	10 000	{0.003, 0.01, 0.03, 0.06}	0.1
CIFAR10	2 500	{0.001, 0.003, 0.01, 0.03}	0.1
CIFAR100	2 500	{0.001, 0.003, 0.01, 0.03}	0.1
Oxford-IIIT Pets	250	{0.001, 0.003, 0.01, 0.03}	0.1
Oxford Flowers-102	250	{0.001, 0.003, 0.01, 0.03}	0.1
VTAB (19 tasks)	1 250	0.001	0.1

B.3 模型修改缩放到V-MoE-15B

典型的密集模型有许多变化，可以与模型稀疏性一起应用，以便缩放模型。为了扩展基础架构，我们添加了专家层的稀疏混合，我们基于[68]进行了以下更改：

- 低精度:我们使用bfloat16而不是float32来存储梯度移动平均。
- 学习率衰减:我们用逆平方根调度(rsqrt)代替线性调度。
- 权重衰减:我们将权重衰减应用于模型中值为0.03的核权重(而偏差没有正则化)，除了头部核，我们应用了3.0的更强正则化。
- 模型头部:我们用一个新的基于自关注的头部替换了令牌头部[20](其中第一个令牌被选择)，该头部还包括一个额外的MLP[68]。

B.4 微调超参数

表7显示了用于微调的超参数。如前所述，它们与Vision Transformer[20]中使用的超参数大致相同，尽管调度长度只有前者的一半。我们还在专家mlp上应用了0.1的专家dropout(如[22]中建议的);这并没有产生显著的差异，通常会略微降低或提高性能。

我们在分辨率为560x560的ImageNet上对V-MoE-15B模型进行了3万步(即大约6个epoch)的微调，基本学习率为0.006。我们使用类似于[20]的去偏Polyak平均，动量为0.999999。

B.5 所有模型的结果和细节

表8:密集和稀疏模型的上游、few-shot和下游性能。还提供了架构细节和培训成本。所有V-MoE模型都有E = 32位专家, C = 1.05。我们指定每个令牌所选专家的数量(k)、JFT-300M epoch的数量、Transformer块的数量(L)、注意头的数量(H)、补丁嵌入大小(D)、MLP的隐藏大小、参数总数、JFT-300M Precision@1(%)、ImageNet 1、5和10次射击精度(%)、ImageNet (INet/Ft.)、CIFAR10、CIFAR100、Oxford-iiit Pets和Oxford Flowers-102的微调精度(%);TPUv3单核上的总训练时间, 以及总训练计算(以exaFLOPs为单位)。

Name	k	Epochs	Blocks	Heads	Embed.	MLP	Params	JFT-300M	INet/1s	INet/5s	INet/10s	INet/Ft.	CIFAR10	CIFAR100	Pets	Flowers	TPUv3-days	ExaFLOPs
ViT-S/32	—	5	8	8	512	2048	36.5M	29.05	29.37	43.21	46.38	73.73	97.95	87.20	91.03	96.78	7.22	12.27
V-MoE-S/32, Last 2	1	5	8	8	512	2048	166.7M	30.93	30.65	46.06	49.47	76.32	98.05	87.93	92.62	95.88	10.83	12.50
V-MoE-S/32, Last 2	2	5	8	8	512	2048	166.7M	33.26	35.49	50.90	54.16	77.10	98.19	88.86	93.20	96.50	12.40	14.40
V-MoE-S/32, Every 2	2	5	8	8	512	2048	296.9M	34.00	37.53	51.75	54.97	77.08	98.23	88.50	94.02	97.86	17.60	16.53
V-MoE-S/32, Last 2	5	5	8	8	512	2048	166.7M	35.49	38.77	53.60	56.94	77.59	98.25	89.25	93.26	97.31	18.49	20.44
ViT-B/32	—	7	12	12	768	3072	102.1M	39.31	40.58	56.37	59.63	80.73	98.61	90.49	93.40	99.27	27.62	56.08
V-MoE-B/32, Last 2	1	7	12	12	768	3072	395.0M	41.41	44.49	60.14	63.63	81.70	98.88	91.28	94.85	99.21	30.59	56.41
V-MoE-B/32, Last 2	2	7	12	12	768	3072	395.0M	43.17	48.04	62.45	65.72	82.60	98.67	91.47	95.25	99.21	36.80	62.75
V-MoE-B/32, Every 2	2	7	12	12	768	3072	980.6M	43.37	47.57	62.88	65.94	82.21	98.89	91.73	95.39	99.60	54.88	76.09
V-MoE-B/32, Last 2	5	7	12	12	768	3072	395.0M	43.94	49.07	63.33	66.68	82.72	98.87	91.46	95.07	99.24	49.11	81.75
ViT-L/32	—	7	24	16	1024	4096	325.3M	46.98	50.95	66.64	69.77	84.37	99.19	92.52	95.83	99.45	97.30	196.13
V-MoE-L/32, Last 2	2	7	24	16	1024	4096	845.8M	49.68	54.52	69.90	72.80	85.04	99.24	92.50	96.34	99.08	110.65	207.94
ViT-B/16	—	7	12	12	768	3072	100.5M	44.58	48.21	63.50	66.94	84.15	99.00	91.87	95.80	99.56	95.04	224.45
V-MoE-B/16, Last 2	1	7	12	12	768	3072	393.3M	47.21	51.98	67.94	70.93	84.71	99.09	92.37	96.40	99.57	106.95	225.78
V-MoE-B/16, Last 2	2	7	12	12	768	3072	393.3M	48.31	54.92	68.84	71.81	85.39	99.21	92.78	96.56	99.63	130.86	250.70
V-MoE-L/32, Every 2	2	7	24	16	1024	4096	3448.2M	49.31	53.61	69.21	72.02	84.81	99.18	93.02	96.32	99.33	165.51	267.10
V-MoE-B/16, Every 2	2	7	12	12	768	3072	979.0M	49.31	55.45	69.60	72.50	85.26	99.16	92.76	96.74	99.20	201.40	303.24
ViT-L/16	—	14	24	16	1024	4096	323.1M	53.40	60.25	74.36	76.62	87.12	99.33	93.93	97.12	99.63	651.26	1572.92
V-MoE-L/16, Last 2	1	14	24	16	1024	4096	843.6M	55.80	60.53	75.81	78.00	87.47	99.39	94.39	97.09	99.39	698.14	1577.40
V-MoE-L/16, Last 2	2	14	24	16	1024	4096	843.6M	56.76	61.46	76.53	78.64	87.54	99.29	94.19	97.37	99.58	761.27	1666.10
V-MoE-L/16, Every 2	2	14	24	16	1024	4096	3446.0M	57.65	62.41	77.10	79.01	87.41	99.48	94.64	97.55	99.38	1205.99	2177.14
ViT-H/14	—	14	32	16	1280	5120	655.8M	56.68	62.34	76.95	79.02	88.08	99.50	94.71	97.11	99.71	2387.99	4276.42
V-MoE-H/14, Last 5	2	14	32	16	1280	5120	2688.6M	60.12	62.95	78.08	80.10	88.23	99.53	94.86	97.17	99.67	2735.70	4750.73
V-MoE-H/14, Every 2	2	14	32	16	1280	5120	7160.8M	60.62	63.38	78.21	80.33	88.36	99.58	94.91	97.45	99.68	3477.18	5795.35
V-MoE-15B	2	—	48	16	1408	6400	14705.1M	—	68.66	82.78	84.29	90.35	—	—	—	—	16775.50	33943.30




图8:不同模型在(a) JFT-300M、(b) 5-shot ImageNet和(c)全ImageNet上的微调性能与总训练时间(TPUv3-core-days)的函数关系。颜色代表不同的VIT变体, 标记代表最后n个偶数块上的标准●VIT或▣V-MoEs。这些线表示VIT(虚线)和V-MoE(实线)变体的帕累托边界。

B.6 JFT计算精度at-1

JFT是多标签的, 它包含类的层次结构。然而, 为了在一处的计算精度, 我们忽略了这个层次结构:给定对图像的预测, 我们只看预测概率最高的类是否确实是图像的真实标签之一。

B.7 重复数据删除训练

表9显示了Imagenet重复数据删除对使用V-MoE-S/32的训练数据的影响。总的来说, 我们没有观察到重复数据删除后的一致和显著的效果。种子之间的差异是显著的, 并且除了in /1shot -重复数据去重复模型的情况外, 在少数投篮评估中可以优于(或低于)原始模型。




图9:稀疏和密集模型的上游性能。(a)中的x轴表示训练过程中所需的总FLOPs，而(b)表示相同硬件的总训练时间。

表9:V-MoE-S/32 ImageNet重复数据删除对fewshot训练数据的影响为了测试在训练集中删除一些与ImageNet“接近”的图像的效果，我们在重复数据集上训练了三个具有不同种子的V-MoE-S/32模型，并比较它们的少数镜头性能，如下所示。结果的差异是相当大的。原始模型在1投上占主导地位，而3粒种子中有2粒在5投、10投和25投上的表现优于原始模型。去重复数据集总体上包含了更多的图像，但我们将训练集限制在原始大小(约305M)，并对相同的时代进行了训练。

Model	Dedup	Seed	IN/1shot	IN/5shot	IN/10shot	IN/25shot
V-MoE-S/32	No	0	37.53	51.75	54.97	57.44
V-MoE-S/32	Yes	0	34.07	49.34	52.21	55.11
V-MoE-S/32	Yes	1	35.63	51.95	55.79	58.19
V-MoE-S/32	Yes	2	36.72	53.09	56.50	58.84